Experiment Queue — ARC WhestBench 2026 (Phase 2)

হালনাগাদ: 2026-09-25 (audit clean-up: Q4/Q6/Q17 dead, duplicate Q18 renamed) · Best graded: #332110 score 5.1284e-9 (raw 2.1046e-8) — v40fb (FB 1.25 + beta 1.2). আগের: #331787 5.137e-9. Plain chain on public MLP #0: final MSE 2.290e-8. Channel oracle (mean closure-e সত্যিকারের মান): variance -47%, kappa4 diagonal -30%, kappa3 diagonal -14%, তিনটাই -94%. Q5: closure নিখুঁত; error = প্রতি layer-এর নতুন kappa3/kappa4 ভুল, যা mean ও covariance দিয়ে জমে। Horizon oracle: kappa3 স্মৃতি খুব লম্বা — ১০ বয়স রাখলেও layer 15-এ 16% error; বয়সের অবদান প্রায় সমান ও লম্ব।

সব AI model-এর (Astra, Fable, GPT...) আর নিজেদের যে ধারণাগুলো পরীক্ষা করার মতো, সেগুলো এখানে priority অনুযায়ী সাজানো। P1 = সস্তা আর বড় সম্ভাবনা, এখনই করতে হবে; P2 = P1-এর পরে; P3 = দামি বা শর্তসাপেক্ষ। মৃত (পরীক্ষা করে ব্যর্থ) ধারণাগুলো শেষে আছে, যাতে আবার সময় নষ্ট না হয়।

সংক্ষেপ (বাকি ও চলমান)

ID	Priority	Status	বিষয়	খরচ
Q14	P2	বাকি	Mixed-coordinate readout: Q8-এর kappa4 term সস্তায় (তৃতীয় leg-টা আগের coordinate-এ রেখে)	17-34 u (Astra)
Q15	P2	বাকি	S=2 'রহস্য'-এর partner channel খোঁজা (সস্তা replay)	~3টা chain run (offline) + ~1 u replay
Q16	P2	বাকি	Join-এ eigen-truncated basis (aug64) — 100-MLP যাচাই	+0.5% util
Q13	P3	বাকি	Variance 'super-closure' (bivariate diagram table cost 4/5)	~1-3 u
Q9	P3	বাকি	Joint knob search	Kaggle CPU

P2 — P1-এর পরে

Q14 Mixed-coordinate readout: Q8-এর kappa4 term সস্তায় (তৃতীয় leg-টা আগের coordinate-এ রেখে)

বাকি

উৎস: Astra R9 §1-3

কী করতে হবে	প্রতি source-এ আলাদা projection না করে, source-গুলোর যোগফল R = S Q^T আগে বানিয়ে পরে একবার B^T দিয়ে গুণ; newborn-এর identity leg একটা product বাঁচায়। শুধু হিসাবের ক্রম বদল — accuracy একই থাকে।
প্রমাণ / এখন পর্যন্ত	Astra-র হিসাবে অতিরিক্ত খরচ 17-34 u (অংশবিশেষ এখনও মাপা হয়নি); break-even 25 u (যদি -8.8% বজায় থাকে)। 20 u-তে score মাত্র +1.8% ভালো, 35 u-তে 3.5% খারাপ। Astra নিজেই বলেছে: এটা moonshot না, leader-দের খরচের কাছেও যায় না।
খরচ	17-34 u (Astra)
পাস করার শর্ত	পূর্ণ metered খরচ <= 25 u আর -8.8% হুবহু reproduce
পরের ধাপ	প্রথমে layer 14-এ identity যাচাই (R_total B^T = D21, 1e-5 পর্যন্ত)।
File	consultations/ai-assistant-suggestions/GPT Astra 6 Ultra/Round_9_Astra_Architecture_Assessment.pdf

Q15 S=2 'রহস্য'-এর partner channel খোঁজা (সস্তা replay)

বাকি

উৎস: Astra R9 §5

কী করতে হবে	S = 1, 1.25, 2-এর variance/kappa3/kappa4 trajectory রেকর্ড করে, প্রতিটা channel-এ teacher মান বসিয়ে mean closure replay — কোন channel-এ oracle দিলে optimum S=1-এর দিকে সরে।
প্রমাণ / এখন পর্যন্ত	Astra: সাধারণ quadratic cancellation দিয়েই ব্যাখ্যা হয় (E(t) = 1 + A t + B t^2, A = -0.034, B = 0.068 -> t = 0.25-এ -0.43%, মাপা -0.35..-0.8%-এর সাথে মেলে)। অর্থাৎ 'রহস্য' আসলে রহস্য না — restored term সত্যিকারের উন্নতি, কিন্তু আরেকটা ভুল তাকে ঢেকে দেয়।
খরচ	~3টা chain run (offline) + ~1 u replay
পাস করার শর্ত	কোনো channel-এর oracle optimum-কে S=2-এর দিকে সরালে সেই channel-ই partner
পরের ধাপ	সময় পেলে।

Q16 Join-এ eigen-truncated basis (aug64) — 100-MLP যাচাই

বাকি

উৎস: নিজের (moonshot A, V41)

কী করতে হবে	Join-এর সময় range finder-এর বদলে: transported old basis + joiner-এর ৬৪টা নতুন দিক, full core-এর eigen-decomposition দিয়ে r = 384-এ কাটা।
প্রমাণ / এখন পর্যন্ত	দুই teacher network: util +0.5%, MSE -1.0% / -1.1%, score -0.5% / -0.55%।
খরচ	+0.5% util
পাস করার শর্ত	100-MLP paired score < 1 - 2 SE
পরের ধাপ	Grid-এর সেরা setting-এর সাথে একসাথে Kaggle-এ।
File	experiments/variants/make_v41join.py

P3 — শর্তসাপেক্ষ / দামি

Q13 Variance 'super-closure' (bivariate diagram table cost 4/5)

বাকি

উৎস: GPT 5.6 Sol High R7 Q1

কী করতে হবে	V29-এর pair closure table-এ আরও diagram (degree <= 4 block) যোগ।
প্রমাণ / এখন পর্যন্ত	Q5: সত্যিকারের input দিলে closure-এর বাকি error মাত্র ~9-13% (তার একটা অংশ teacher noise) — তাই এই পথের সর্বোচ্চ লাভ সীমিত।
খরচ	~1-3 u
পাস করার শর্ত	teacher-forced projected dvar >= 25% কমলে
পরের ধাপ	কম priority।

Q9 Joint knob search

বাকি

উৎস: নিজের (K3z-B)

কী করতে হবে	সব knob একসাথে score-এর উপর coordinate search।
প্রমাণ / এখন পর্যন্ত	100-MLP ফল: knob-গুলো score-optimum-এ (age2_8, qpass-এ accuracy বাড়লে সমান হারে খরচ বাড়ে) — joint search-এ বড় লাভের আশা কম।
খরচ	Kaggle CPU
পাস করার শর্ত	100-MLP-এ paired gain
পরের ধাপ	Q3-এর ফল আসার পর।

শেষ হয়েছে (সফল / মৃত)

Q17 Young tier (~104 u) অর্ধেক খরচে — Round 10 prompt

মৃত

উৎস: নিজের (moonshot A)

কী করতে হবে	Age 1-4 source-এর transport + contraction কম product-এ: A = P a_b ব্যবহার, পরপর source-এর shared propagator factor, age-1/2 closed form, batched contraction।
প্রমাণ / এখন পর্যন্ত	Cost ledger: young transport ~54 u + contraction ~50 u। একজন leader সমান accuracy অর্ধেক খরচে দেখিয়েছে। নিজের বীজগণিত (24 Sep): (১) A = P a_b দিয়ে A-transport বাদ — লাভ নেই, (P o A) term-এ A-র entry-wise মান লাগে তাই A বানাতে n^3 লাগেই; (২) P_old = P_new M — তৈরি করতেও n^3; (৩) batching — FLOP একই; (৪) age-1 P = W আগেই কাজে লাগানো। Hadamard গুণফল full-rank (Khatri-Rao wall) — প্রতি source-layer ৪টা n^3 এই কাঠামোর ন্যূনতম। সমাধান থাকলে কাঠামোর বাইরে। | 24-25 Sep: Round 10 বন্ধ — Sonnet-এর exact contraction-order search + ৪টা বাইরের উত্তর: যেকোনো ক্রমে 193 square product (D21)।
খরচ	গবেষণা
পাস করার শর্ত	D21 relative error <= 2% রেখে <= 55 u

Q18a Finite-Horizon Query Response (h = 2): ২ layer-এর kappa3 স্মৃতি query-space-এ, বাকিটা tree দিয়ে

মৃত

উৎস: GPT 5.6 Sol R9 (FHQR-2)

কী করতে হবে	Source bank-এর বদলে দুটো global n x n response matrix H = K3[:, Q, Q] (Q = পরের ১ ও ২ layer-এর query) বয়ে নেওয়া; পুরোনো অংশ dressed tree দিয়ে পূরণ।
প্রমাণ / এখন পর্যন্ত	Horizon oracle (Fable-এর dense source capture, source-যোগফল chain D21-এর সাথে 1.5e-7 পর্যন্ত মেলে): শেষ h বয়স রেখে বাকি বাদ দিলে D21 error — layer 15: h2 84%, h4 65%, h6 46%, h8 31%, h10 16%; layer 11: h2 72%, h8 10%। প্রতিটা বয়স প্রায় সমান ভাগ দেয় (~0.15-0.20), আর অবদানগুলো [সংশোধিত 24 Sep: লম্ব না — বয়সগুলো coherent, বর্গের যোগফল 0.24-0.49]। FHQR-2 মৃত; Sol-এর নিয়মে: leader-রা লম্বা স্মৃতি রাখে কিন্তু একেবারে ভিন্ন সস্তা coordinate-এ। | ফল (q18_k4_horizon.py, N=1e6, MLP#0): L−h-এ সব স্মৃতি মুছে Gaussian দিয়ে h ধাপ আসল network চালালে decisive neuron-এ κ4 level L12: h=1/2/3/4/6 → 2/6/12/18/35%, L16: 3/2/5/9/20%; teacher-এর সাথে pattern corr L12 0.23/0.40/0.53/0.67/0.78, L16 0.20/0.41/0.59/0.65/0.77; best-scale errG4 h=2: 0.90/0.99, h=6: 0.37/0.63 — chain 0.19/0.21। শেষ ২ ধাপের জন্ম κ4-এর মাত্র 2-6% বহন করে; ৬ ধাপেও 20-35%। κ4-এর স্মৃতি κ3-এর মতোই লম্বা: young κ4 carrier মৃত; κ4 lever-এর জন্য পুরো κ4 source chain লাগবে — খরচে বন্ধ।
খরচ	~82-90 u (Strassen) দাবি
পাস করার শর্ত	teacher-forced D21 error <= 2.5%
File	experiments/probes/q18_k4_horizon.py

Q1 Quartic kappa4 kernel (সস্তা version) — kappa4 diagonal-এর নতুন হিসাব

মৃত

উৎস: Astra R7 §3-4

কী করতে হবে	প্রতিটা ReLU-তে নতুন করে quartic response polynomial F0 হিসাব; তার non-pair অংশ + chain-এর pair অংশ দিয়ে পরের layer-এর kappa4 diagonal। Global rule: k4 = 0.3 x chain + 0.7 x (P_chain + 1.25 x kernel non-pair)।
প্রমাণ / এখন পর্যন্ত	non-pair অংশের corr 0.63-0.78 (দুই network)। End-to-end (mean closure-এ): A=0.5,S=1.5 -> MLP #0 -6.4%, synthetic -2.6%; A=0.3,S=1.25 -> -5.0% / -1.5%। Pchain ছাড়া (শুধু chain kappa4 + kernel) কাজ করে না — double count। GPT Sol High R7-এর K3+C '3+2' term (সস্তা t_rep, chain-এর D21/D3 দিয়ে) যোগ করলে non-pair corr 0.73-0.83 (আগে 0.68-0.78), scale ঘাটতি 1.16-1.87 (আগে 1.34-2.16) — কিন্তু দরকারি neuron-এ corr মাত্র +0.01-0.04, G4-weighted error একই (x0.925)। শেষ layer/দরকারি neuron পরীক্ষা (A=0.5,S=1.5): সব layer সব neuron -6.4% / -2.6% @ ~42 u; সব layer দরকারি neuron -5.2% / +0.3% @ ~22 u; layer 8-16 -3.5% / -1.1% @ ~11.5 u; layer 11-16 -2.8% / -0.2% @ ~7 u। কোনো setting-এ score-এ net লাভ নেই — বর্তমান রূপে মৃত।
খরচ	3টা product/layer: শুধু দরকারি ~400 neuron-এ ~18 u (+7%), সবার জন্য ~26 u (+10%)
পাস করার শর্ত	এখনকার অবস্থায় net ≈ 0 (লাভ 2.6-6.4% বনাম খরচ 7-10%)। লাভজনক করতে: খরচ অর্ধেক, বা accuracy দ্বিগুণ (Q6/Q8)
পরের ধাপ	শুধু যদি Q12 (211 hypertree) kernel-কে অনেক বেশি নিখুঁত করে তবেই আবার।
File	experiments/probes/probe_astra7_k4.py, experiments/chain/a7_kernel_e2e.py

Q2 R7_FB_SCALE = 1.25 (feedback constant একটু বাড়ানো)

সফল

উৎস: Fable R7

কী করতে হবে	Port-এর সময় Edgeworth-এর দুটো K x C term-এর অর্ধেক বাদ পড়েছিল; পুরোটা ফেরালে (2.0) খারাপ, 1.25 সামান্য ভালো।
প্রমাণ / এখন পর্যন্ত	100 MLP, paired (base bit-identical): fb1.25 score x0.9963 +- 0.0008; fb1.5 x1.0001; fb1.25 + beta1.2 x0.9946 +- 0.0007 (73% network-এ ভালো), খরচ শূন্য। Submit: v40fb (#332110), আনুমানিক LB 5.109e-9। GRADED: #332110 score 5.1284e-9 (raw 2.1046e-8) — নতুন best (আগে 5.137e-9): -0.17%, local অনুমানের (-0.54%) চেয়ে কম (লুকানো network আলাদা)। | FB x beta grid (100 MLP, paired vs shipped 1.25/1.2, 24 Sep): fb1.15/b1.2 +0.10% +-0.03, fb1.35/b1.2 +0.00% +-0.03, fb1.15/b1.3 +0.12% +-0.05, fb1.35/b1.1 +0.08% +-0.05 — shipped setting সেরা (সমতল শীর্ষ); fb1.25/b1.1 +0.04% +-0.03, fb1.25/b1.3 -0.01% +-0.03 — কোনো পার্থক্য নেই; grid শেষ।
খরচ	0 u (শুধু constant)
পাস করার শর্ত	100-MLP suite-এ paired gain > SE
পরের ধাপ	শেষ।
File	experiments/variants/r7_estimator_fbscale.py

Q3 100-MLP knob eval (৬টা variant) — Kaggle-এ চলছে

সফল

উৎস: নিজের (K3z-B)

কী করতে হবে	beta1.2, lam0.9, row0.25, qpass2_3, age2_8, qpass_2 — বর্তমান best-এর সাথে একই 100 MLP-এ paired তুলনা।
প্রমাণ / এখন পর্যন্ত	runner-b ও c শেষ (100 MLP, paired, bit-identical deterministic base): row0.25 score x1.0003; qpass2_3 x1.0006; age2_8 raw x0.9910 (79% network-এ ভালো) কিন্তু util x1.0097 -> score x1.0006; qpass_2 raw x0.9904 কিন্তু util x1.083 -> score x1.073। কোনোটাই submit-যোগ্য না — chain score-optimum-এ (accuracy 1% = খরচ 1%)। Harness-এর SE +-0.01-0.15%। LB অনুমান = 5.137e-9 x paired score ratio (LB raw = local x 0.956)। Kaggle wall median ~111 s, max ~134 s — বাড়তি হিসাবে সময়ের ঝুঁকি। runner-a চলছে। runner-a: beta1.2 score x0.9993 +- 0.0005 (বিনা খরচে সামান্য ভালো, Q2-এর সাথে মিলিয়ে পরীক্ষা হচ্ছে); lam0.9 x1.0026 (খারাপ)। base তিন runner-এ bit-identical -> base আর চালানোর দরকার নেই।
খরচ	Kaggle CPU (আমাদের সময় লাগে না)
পাস করার শর্ত	score (MSE x util) significant ভাবে কম হলে submit
পরের ধাপ	শেষ। কোনো variant একা submit-যোগ্য না।
File	kaggle/runners/runner_{a,b,c}, kaggle/estimators/set_{a,b,c}

Q4 Oracle: সত্যিকারের D21 শুধু feedback leg-এ

মৃত

উৎস: Fable R7

কী করতে হবে	kappa3 slice error-এর 55-65% এখনও ব্যাখ্যা হয়নি; closure-এর cross-talk কিনা আলাদা করা।
প্রমাণ / এখন পর্যন্ত	Fable: first-order theory 35-45% ব্যাখ্যা করে। Fable R8: 'সব index আলাদা' kappa3 error-এর ~55% দ্বিতীয় ক্রম পর্যন্তও ব্যাখ্যা হয় না — এই formulation-এর মেঝে। | 25 Sep: Opus R12 চালিয়েছে — সত্যিকারের D21 শুধু feedback leg-এ ×0.9999 (কোনো প্রভাব নেই)।
খরচ	একটা chain run (offline oracle)
পাস করার শর্ত	slice error বা final MSE উল্লেখযোগ্য কমলে -> সস্তা approximation খোঁজা

Q5 Teacher-forced bivariate closure: কোন input covariance error বানায়

সফল

উৎস: Astra R7 §1-2

কী করতে হবে	layer 8, 12, 15-এ closure-কে সত্যিকারের cumulant দিয়ে চালানো; আলাদা করে শুধু kappa31 / K22 / D21 বদলে দেখা, কোনটা fresh covariance error (4.2e-5) কমায়।
প্রমাণ / এখন পর্যন্ত	ফল (weighted next-layer variance error, layer 7 / 14): সব input সত্যিকারের -> 0.127 / 0.092; শুধু mu, var, C -> 0.376 / 0.185; শুধু kappa3 -> 0.715 / 0.853; শুধু kappa4 -> 0.960 / 0.998। সিদ্ধান্ত: closure প্রায় নিখুঁত; covariance error-এর বেশিরভাগ (depth-এ 81%) আগের layer থেকে জমে আসা mu/C error; নতুন error আসে kappa3 (15-28%) ও closure অবশিষ্ট থেকে। variance-এর জন্য আলাদা কোনো term সারানোর নেই — প্রতিটা layer-এর নতুন kappa3/kappa4 error কমাতে হবে।
খরচ	<10 u offline
পাস করার শর্ত	কোনো একটা input বদলালে projected variance error অনেক কমলে -> সেই input ঠিক করাই লক্ষ্য
পরের ধাপ	Q10 (E-এর structure) এখনও অর্থবহ; মূল lever এখন kappa3 slice ও kappa4 diagonal-এর fresh error।
File	data/kaggle_out/kaggle_out_k4post

Q6 Kernel-এ K4 x C term যোগ

মৃত

উৎস: Astra R7 appendix A

কী করতে হবে	Harmonic input kappa4-এর সাথে covariance-এর পরের order-এর term (দুটো অতিরিক্ত query product)।
প্রমাণ / এখন পর্যন্ত	Q1-এর kernel depth-এ magnitude কম ধরে (দরকারি scale 1.3 -> 2.2); এই term সেই ঘাটতির অংশ হতে পারে। | 25 Sep: Q1 মৃত, আর Opus R12 (D22) দেখিয়েছে kernel-এর সস্তা রূপগুলো নিট ≤ 0; κ4-এর গভীর pattern দীর্ঘ স্মৃতি (C15, Q18)।
খরচ	+2m/n u/layer (~+0.7 u per layer at m=350)
পাস করার শর্ত	one-layer diagnostic-এ non-pair corr/slope ভালো হলে

Q7 Kernel থেকে (3,1) slice-ও নেওয়া

মৃত

উৎস: Astra R7 §4

কী করতে হবে	একই polynomial-এর gradient থেকে kappa31 slice; covariance channel-কেও প্রভাবিত করতে পারে।
প্রমাণ / এখন পর্যন্ত	Fable R8: (3,1) sector নগণ্য (1e-3-এর মধ্যে 3e-5)।
খরচ	~42 u মোট
পাস করার শর্ত	raw MSE >13.9% কমতে হবে
পরের ধাপ	Q1 আর Q5 দুটোই ইতিবাচক হলে।

Q8 K3 x C directional query (kernel-এর পূর্ণ version)

মৃত

উৎস: Astra R7 §5 + Fable R8

কী করতে হবে	Kernel-এ বাদ পড়া K3 x C term, source leg পুনর্ব্যবহার করে।
প্রমাণ / এখন পর্যন্ত	Fable R8: kernel-এর depth-ঘাটতি হলো ঠিক এই (1,1,1,1) K3 x C term — chain-এর নিজের source থেকে 'সব index আলাদা' kappa3 দিয়ে (Sol-এর t_rep এই sector দেখতেই পারে না)। মাপা coefficient 1.0 +- 0.1 (theory 1); দরকারি neuron-এ corr 0.69-0.75 -> 0.75-0.81; G4-weighted kappa4 error 0.095/0.116/0.157/0.193/0.197 (L4/8/12/15/16; chain 0.124/0.142/0.193/0.199/0.210)। ageটা 1-4 source-এ ~90%, 1-2-এ ~65%। End-to-end (MLP #0, A=0.5,S=1.5 + term): -8.8% (2.0893e-8) — কিন্তু খরচ ~140 u (+55%), চলবে না। সস্তা সংস্করণ (MLP #0; synthetic run session restart-এ থেমে গেছে): layer 8-16 + দরকারি neuron + ২ source -> -4.2% @ ~35 u classical (+13%); সব layer + দরকারি neuron + ২ source -> -6.25% @ ~52 u; term ছাড়া layer 8-16 -> -3.5%। কোনোটাতেই score-এ net লাভ নেই — বর্তমান কাঠামোয় মৃত।
খরচ	পূর্ণ: ~140 u; সস্তা সংস্করণ (layer 8-16, |alpha|<1.5, ২টা নতুন source): ~26 u classical / ~13 u Strassen
পাস করার শর্ত	সস্তা সংস্করণে raw MSE > 9% (classical) বা > 5% (Strassen) কমলে
পরের ধাপ	শুধু নতুন architecture-এ (term-কে transport product-এর ভিতরে ঢুকিয়ে) আবার বিবেচনা।
File	experiments/probes/r8_k4_1111.py, r8_k4_dist_e2e.py; consultations/fable/ROUND8_fable_synthesis.md

Q12 Kernel-এ nine cheap (2,1,1) hypertree class যোগ

মৃত

উৎস: GPT 5.6 Sol High R7 Q2.3

কী করতে হবে	Birth-এর (2,1,1) অংশের ১২টা symmetry class-এর মধ্যে ৯টা hypertree — C, C.^2, D21, D21^T দিয়ে n x m message-এ হিসাব করা যায়; ৩টা non-hypertree (triangle ইত্যাদি) বাদ।
প্রমাণ / এখন পর্যন্ত	Fable R8: exact (2,1,1) law + Sol-এর nine hypertree + triangle: fixed-coef R2 <= 0.07, দরকারি neuron-এ প্রতিটা layer-এ খারাপ।
খরচ	+5-15 u (late-layer version)
পাস করার শর্ত	kappa4 residual RMS মোট >= 40% কমলে; নইলে বাদ
পরের ধাপ	ARC-এর factor_k4.py / TERM_TABLE_211 থেকে graph list নিয়ে weighted capped evaluator।

Q10 Covariance error E কি target neuron-এর দিক থেকে low-rank?

মৃত

উৎস: GPT 5.6 Terra R7 Q1.2

কী করতে হবে	E = C_true_post - C_chain_post; তার eigen-decomposition; top-k দিক দিয়ে দরকারি ~350 neuron-এর variance correction w_i^T E w_i কতটা ধরা যায় (k = 4, 8, 16, 32)। Top দিকগুলো কোনো জানা vector-এর (mean, C-এর eigenvector) সাথে মেলে কি না।
প্রমাণ / এখন পর্যন্ত	E-র top-8 দিকে 26-49% energy, আর সেগুলো post-ReLU mean vector (overlap 0.75-0.79) ও C-র top eigenvector-এর (0.68-0.82) দিকে — coherent ভুল। কিন্তু দরকারি neuron-এর (|alpha|<0.75) variance correction আসে এলোমেলো full-rank অংশ থেকে: k=32-এ error 0.81-1.04, k=256 লাগে। low-rank correction অচল।
খরচ	শুধু offline diagnostic (কয়েক মিনিট)
পাস করার শর্ত	k <= 32-এ 0.1% relative accuracy, আর দিকগুলো chain-এর কোনো জানা quantity দিয়ে predict করা গেলে
পরের ধাপ	Q5 শেষ হলে।
File	experiments/probes/q10_error_rank.py

Q11 Coupled surrogate দিয়ে Monte Carlo — variance সত্যি কত গুণ কমে (kill-test)

মৃত

উৎস: Astra R7 §6 / GPT Terra R7 Q1.4 / Grok R7 1c

কী করতে হবে	Linearized network G(x) = m + J x (একই x দিয়ে coupled) control variate; ~2000 sample-এ variance/kappa3/kappa4 correction-এর variance reduction factor মাপা।
প্রমাণ / এখন পর্যন্ত	Coupled linear surrogate-এর সাথে correlation (variance statistic): layer 2 -> 0.73, 4 -> 0.50, 8 -> 0.32, 16 -> 0.19; variance কমে মাত্র x1.0-2.2 (লাগত x100)। Sampling পথ বন্ধ; Grok-এর 40x দাবি ভুল প্রমাণিত।
খরচ	CPU-তে কয়েক মিনিট (numpy)
পাস করার শর্ত	reduction >= 100x হলে তবেই এগোনো
পরের ধাপ	সময় পেলে দ্রুত kill-test।
File	experiments/probes/q11_surrogate_cv.py

D1 Covariance patch (C^3, C^4, C x kappa31 term)

মৃত

উৎস: Astra R7 §2

কী করতে হবে	V29-এর (1,1) closure-এ বাদ পড়া তিনটা term।
প্রমাণ / এখন পর্যন্ত	term-গুলো খুব ছোট (rms 2-3e-6 বনাম error 6.5-9e-5), error-এর সাথে corr ~0, projected variance error x0.998-1.007।
খরচ	<0.2 u
File	experiments/probes/probe_astra7_cov.py

D2 Monte Carlo / control variate দিয়ে তিনটা সংখ্যা

মৃত

উৎস: Astra R7 §6

কী করতে হবে	Sampling দিয়ে variance/kappa3/kappa4 correction।
প্রমাণ / এখন পর্যন্ত	Theory: 100x variance কমাতে surrogate corr >= 0.997 লাগবে; 10,000 sample = 156 u, তাতেও variance error 1.4%।

D3 kappa3 transport curvature, exact old tier, R_FB 128, FB_SCALE 2.0

মৃত

উৎস: Fable R7 / নিজের

কী করতে হবে	kappa3 slice error কমানোর চেষ্টা।
প্রমাণ / এখন পর্যন্ত	curvature-এর coherent অংশ নেই; exact old tier -3.9% MSE / +19% cost; R_FB 128 -3.1% / +43%; FB_SCALE 2.0 +3.4% খারাপ।
File	consultations/fable/ROUND7_fable_report.md

D4 kappa4 diagonal-এর সস্তা পথ: V39 multiplier, pairwise, 13-feature, star source, |kappa3|

মৃত

উৎস: নিজের (23 Sep)

কী করতে হবে	kappa4 diagonal ঠিক করার চেষ্টা।
প্রমাণ / এখন পর্যন্ত	V39 16-26% খারাপ; pairwise corr 0.24-0.59; feature 0.19->0.18; star depth-এ 10%; |D3| শুধু অদরকারি neuron-এ।
File	docs/build_notes.py K3ab-K3ad

D5 Grok-এর D21-scaling covariance term, Grok-এর pairwise kappa4 (6 w2 K22 w2 + 4 w3 K31 w), Copilot-এর Hutchinson probe ও aggregate matrix

মৃত

উৎস: Grok R7 1b, Q2 / Copilot R7

কী করতে হবে	একই ধরনের পুরোনো প্রস্তাব।
প্রমাণ / এখন পর্যন্ত	D21-ধরনের term-এর scaling: closure-term regression R2 <= 0.08 (R27); pairwise kappa4 সত্যিকারের post slice দিয়েও corr 0.24-0.59 (K3ad); Hutchinson-এর জন্য অজানা error E লাগে; aggregate matrix family আগেই মৃত (K3e)।
File	consultations/ai-assistant-suggestions/{Grok,Copilot}/*Round*7*

D6 Random-weight mixture memo; Gemini-র kappa3 x kappa3 covariance term; quadratic surrogate MC

মৃত

উৎস: DeepSeek R7 / Gemini R7 Q1, Q3

কী করতে হবে	(ক) 'weight random ধরে' Gaussian mixture: kappa3_iii = 0, 300 sample যথেষ্ট; (খ) Cov-এ sum_ab k3(j,a,b) k3(k,a,b) term; (গ) 2nd-order surrogate control variate।
প্রমাণ / এখন পর্যন্ত	(ক) আমাদের weight fixed; teacher-এ kappa3_iii rms ~1e-2 আর chain তার সাথে slope 1.00-তে মেলে — দাবি ভুল। (খ) Cov(relu z_j, relu z_k) শুধু (z_j, z_k)-এর যৌথ distribution-এর উপর নির্ভর করে — অন্য index ঢুকতে পারে না; Q5-এ সত্যিকারের input দিলে closure নিখুঁত। (গ) মাপা: correlation layer 2 -> 0.967 (x15), 4 -> 0.889, 8 -> 0.733, 12 -> 0.454, 16 -> 0.00 — গভীরে ভেঙে পড়ে।
File	experiments/probes/q11_surrogate_cv.py (SURR=quad)

D7 DeepSeek 7.1: 'missing (2,1) kappa3 x kappa3 covariance term', sparse pair-neighbour variance, rank-R kappa4 CP

মৃত

উৎস: DeepSeek R7.1

প্রমাণ / এখন পর্যন্ত kappa3 x kappa3 term (d21T*d21T, d21*d21T) chain-এর (1,1) table-এ আগে থেকেই আছে, আর Q5-এ closure নিখুঁত; error পুরো matrix জুড়ে ছড়ানো (Q10) তাই sparse neighbour কাজ করবে না; rank-R kappa4 CP হলো মৃত aggregate/Tucker পরিবার (K3e, K3j)।

File consultations/ai-assistant-suggestions/DeepSeek, GPT 5.6 Terra

D8 Variance adjoint recursion, top-5% stratified MC, 'closed-form' (2,1,1)/(1,1,1,1) kappa4, Rao-Blackwell MC

মৃত

উৎস: অজ্ঞাত AI (chat-এ paste করা, 23 Sep)

কী করতে হবে চারটা প্রস্তাব।

প্রমাণ / এখন পর্যন্ত (১) chain-এর নিজের C থেকে variance হিসাব — accuracy বাড়ে না, আর একটা adjoint vector-এ বহু quadratic form হয় না; (২) অজানা error ΔC sample করা অসম্ভব, আর error full-rank (Q10); (৩) সূত্র ভুল — (1,1,1,1)-কে sum w^4 kappa4_jjjj লিখেছে (এটা diagonal term, chain-এ আছে), (2,1,1)-এ একটাই index; (৪) weight random ধরেছে (আমাদের fixed), '30x' ভিত্তিহীন (Q11: x1-2), খরচে 1000x ভুল।

D9 kappa3-এর দ্বিতীয় ক্রম (K x K), D21 error-এর coherent অংশ, kappa4 memory (পুরোনো star), non-Gaussian vertex weight

মৃত

উৎস: Fable R8 (নিজের পরীক্ষা)

কী করতে হবে variance/kappa4 channel-এর উৎস খোঁজা।

প্রমাণ / এখন পর্যন্ত K x K-এর ১২টা term: rms 3e-6-2e-5 বনাম error 2.2e-4 (নগণ্য; ফলে R7-এর 'S=2 কেন খারাপ' ব্যাখ্যাও বাদ, XY knob দরকার নেই); D21 error-এর rank-1 (mu-দিকের) অংশ দরকারি neuron দেখেই না; পুরোনো star birth residual-এর সাথে উল্টো সম্পর্কিত (coef -0.9); vertex weight ratio 1.00।

File experiments/probes/r8_kk_terms.py, r8_k4_memory.py, r8_k4_ngvertex.py, r8_dist_check.py

D10 Explicit all-distinct kappa3 tensor, reverse cubic-functional circuit, শুধু young tier দ্রুত করা

মৃত

উৎস: Astra R9 §4 (derived)

কী করতে হবে নতুন architecture-এর তিনটা সম্ভাব্য দিক।

প্রমাণ / এখন পর্যন্ত Packed kappa3 tensor 0.72 GB, transport ~1567 u/layer; circuit রূপে source-layer প্রতি আবার ~2 u; পুরো young tier (116 u) মুছে দিলেও 144 u থাকে — kappa4 fix-সহ 150 u-তে যেতে young tier-এর চেয়ে বেশি বাঁচাতে হবে।

D11 Join-এ range finder বাদ দেওয়া (transport mode) ও ছোট sketch (aug16/32)

মৃত

উৎস: নিজের (moonshot A, V41)

কী করতে হবে Join-এর খরচ কমানো।

প্রমাণ / এখন পর্যন্ত transport: util -6.6% কিন্তু MSE +6.3% / +1.0%; aug16/32: score +1.3% / +0.8% খারাপ। Join থেকে বড় খরচ বাঁচে না।

File experiments/variants/make_v41join.py

D12 DHMP: source bank বাদ, প্রতি layer-এ dressed tree দিয়ে 'সব index আলাদা' kappa3

মৃত

উৎস: GPT 5.6 Sol R9 (DHMP)

কী করতে হবে	Source-free architecture (দাবি ~74-90 u)।
প্রমাণ / এখন পর্যন্ত	Kill gate (teacher-forced, সত্যিকারের post E, T, d3): পরের D21-এর relative error 40.4% / 38.4% / 36.4% / 36.7% / 36.3% (L4/8/12/15/16) — শর্ত <= 2.5%, chain 4-7%। Tree 'সব index আলাদা' অংশের সাথে corr মাত্র 0.43-0.54 (scale ঠিক, slope 0.88-1.16): বাকি অর্ধেক আগের layer-এর স্মৃতি। Dressed বনাম bare edge পার্থক্য 0.4-1% — paradox-এর ব্যাখ্যাও না।
File	experiments/probes/r9_dhmp_gate.py

D13 বয়সের অক্ষে kappa3 স্মৃতি সংক্ষেপ (age-mode projection)

মৃত

উৎস: GPT 5.6 Sol (Age-Gram test)

কী করতে হবে	সব বয়সের D21 অবদানের Gram matrix-এর প্রথম r mode দিয়ে মোট D21 পুনর্গঠন।
প্রমাণ / এখন পর্যন্ত	সংশোধন: বয়সগুলো লম্ব না, coherent (sum s^2 = 0.25-0.49, mean cosine 0.29-0.39, প্রথম mode 34-47% শক্তি, সব loading একই চিহ্ন)। কিন্তু মোট D21-এর error: layer 15 r1 12.2%, r4 10.3%, r6 8.5%; layer 14 r1 15.4%, r6 9.7%; layer 11 r1 23.5%, r6 7.4% — লক্ষ্য 2%-এর অনেক উপরে। প্রথম mode depth-এ মোটের ~88% ধরে, বাকি ~12% অনেক mode-এ সমানভাবে ছড়ানো।
পরের ধাপ	প্রথম mode layer থেকে layer-এ একটা object হিসেবে transport হয় কি না — Sol-কে প্রশ্ন।
File	experiments/probes/r9_age_gram.py

D14 প্রথম age-mode-কে এক object হিসেবে layer থেকে layer-এ বহন (S_{l+1} = rho T S_l + birth)

মৃত

উৎস: GPT 5.6 Sol (shift-stable coherent carrier)

কী করতে হবে	Age-Gram-এর প্রথম mode-এর ওজনে সব source যোগ করে একটা carrier; পরের layer-এ তার ওজন এক ধাপ সরে যায় কি না।
প্রমাণ / এখন পর্যন্ত	L14 -> L15 (সত্যিকারের transported source দিয়ে): rho* = 0.944, eps_shift = 2.9% (শর্ত <= 2%; 2-5% = 'backbone')। Carrier + birth দিয়ে মোট D21: 13.9% error। মূল কথা: যেকোনো স্থির ওজন একই linear map-এ transport হয়, আর uniform ওজন (মোট kappa3 নিজেই) হুবহু shift-stable — তাই coherent mode সময়ের অক্ষে নতুন কিছু দেয় না। সমস্যা পুরোপুরি SPATIAL: একটা ঘন cubic tensor (মোট) সস্তায় ধরা।
পরের ধাপ	Spatial প্রশ্ন: মোট kappa3-এর কোন representation 3kn column-এর চেয়ে সস্তা আর transport + ReLU-তে টিকে থাকে? (Tucker/TT/ISDF/vector-metric মৃত)
File	experiments/probes/r9_shift_carrier.py

D15 মোট kappa3-এর যেকোনো linear compression যা transport-এ বন্ধ; lazy cubic circuit

মৃত

উৎস: GPT 5.6 Sol (irreducibility + lazy cubic circuit)

কী করতে হবে	(১) প্রমাণ: সব dense M-এর জন্য বন্ধ linear state-এর মাত্রা >= C(n+2,3) ~ 1.8e8 (Sym^3 irreducible)। (২) শুধু birth matrix + M রেখে reverse-mode-এ D21।
প্রমাণ / এখন পর্যন্ত	Circuit-এর গণনা: depth l-এ ~4l square product, মোট ~480, ~245 u — chain-এর 249 u-র সমান (একই tensor network-এর দুই contraction order)। আমাদের সংশোধন: M স্থির ও জানা, তাই আসল সীমা ভবিষ্যৎ readout যা দেখে (প্রতি বাকি layer-এ <= n^2) — mid depth-এ chain-এর ~3kn^2-এর কাছাকাছি, ফ্রি ২x নেই।
পরের ধাপ	Tensor-এর factorisation বদলানো বন্ধ। কী represent করা হচ্ছে সেটা বদলাতে হবে: দরকারি marginal channel (d3, variance, next-layer mean) kappa3 tensor ছাড়া হিসাব।

D16 **Channel-history state (m, C, Y, k4 সব layer-এর) + nonlinear memory closure** মৃত

উৎস: GPT-6 Astra (Round 11)

কী করতে হবে	Source leg বাদ দিয়ে শুধু দেখা যায় এমন channel-এর ইতিহাস রাখা; পরের Y আর k4-এর জন্য একটা nonlinear নিয়ম।
প্রমাণ / এখন পর্যন্ত	Astra নিজেই কোনো নিয়ম দিতে পারেনি (সৎ 'না')। Injection যুক্তি: (a,b,c) all-distinct একটা লুকানো perturbation বর্তমান slice আর diagonal-এ দেখা যায় না, অথচ পরের slice বদলায় — তাই শুধু channel-এ সাধারণভাবে যথেষ্ট তথ্য নেই। বাস্তব MLP-এর ক্ষেত্রে: DHMP (pair state থেকে tree) corr 0.43-0.54, অর্ধেক all-distinct অংশ স্মৃতি; slice transport (K3g) আর learned correction আগেই মৃত। Budget: 125u = প্রতি layer-এ ~15টা square product। | Astra (২য় উত্তর, 24 Sep): আবার সৎ 'না' — S = (mu, C, Y21, d3, d4) state-এর O(n^2) storage আর ~1u/layer covariance transport ঠিক, কিন্তু missing cubic/quartic content-এর nonlinear transition-টাই অজানা; সেটাকে শূন্য খরচ ধরলে ফল 'বানানো' হবে। নতুন কিছু নেই।
পরের ধাপ	Injection test চালানো হয়নি: গঠন অনুযায়ীই পাস/ফেল নির্ধারিত (tautological), বাস্তব family সম্পর্কে কিছু বলে না।
File	Architecture Analysis/Round_11_Astra_Channel_State_Assessment.pdf

D17 **শুধু diagonal kappa3/kappa4 (d3, K4d) বহন + Hadamard-power transport; low-rank(+diag) covariance; rank-1 kappa3** মৃত

উৎস: Round 11: SciMaster 'matrix sketch', 'independent-cumulant', 'diagonal-channel transport'

কী করতে হবে	Source leg আর off-diagonal kappa3 বাদ; পরের d3 = sum Q^3 d3 (+ covariance/tree term); covariance diag + rank r; kappa3 ~ s t(x)t(x)t।
প্রমাণ / এখন পর্যন্ত	One-step teacher-forced (সত্যিকারের post state থেকে): পরের d3-এর error — independence 90-99%, + dressed tree 83-98%, পুরো repeated-index অংশ (off-diag slice লাগে) + tree 22-29% (chain free-run 3.2-4.7%)। d3 প্রায় পুরোটাই off-diagonal kappa3 থেকে আসে। সেরা rank-1 D21: 35-49% error। Diag + rank-r covariance-এর off-diag error r=4/16/32/64: L15-এ 65/43/27/14% (chain 0.7%)। SciMaster-এর 'prototype 115u-তে 1.18x MSE' — কোনো run হয়নি, বানানো ফল।
File	experiments/probes/r11_diag_closure_gate.py

D18 **C, Y21 slice, K4d আর একটা response matrix R (R' = (WoW) R W^T + alpha Y21 + beta C) বহন** মৃত

উৎস: Copilot (Round 11): Response-State Closure

কী করতে হবে	Source বাদ; slice-কে state হিসেবে রেখে linear recursion + fitted coefficient।
প্রমাণ / এখন পর্যন্ত	সবচেয়ে উদার gate (সত্যিকারের post state, একই layer-এ in-sample fit, L15->L16): off-diag D21 error 35.9%, d3 21.6% (chain 6.6% / 4.7%)। R memory term লাভ দেয় মাত্র 0.3%। Slice-থেকে-slice কোনো linear recursion all-distinct স্মৃতি ধরতে পারে না (K3g-এর সাথে একই)।
File	experiments/probes/r11_rsc_gate.py

D19 Source bank-এর বদলে K = kM (~448) deterministic moment-matched particle; সব channel cloud-এর empirical cumulant থেকে

মৃত

উৎস: SciMaster (Round 11): Deterministic Particle Propagation / dNTC

কী করতে হবে	Spherical design / cross-polytope particle, প্রতি particle-এ exact W আর ReLU; খরচ ~K/n u প্রতি layer।
প্রমাণ / এখন পর্যন্ত	সরাসরি free-run (MLP #0, L15): cross-polytope 2048 — variance 3.0%, C off 16%, d3 47%, K4d 183%, D21 74%; দুই-radius 4096 — প্রায় একই; 448 particle — variance 6.7%, D21 160%। Deterministic design আর random Gaussian-এর মধ্যে পার্থক্য প্রায় নেই (প্রথম ReLU-র পরে design-এর গুণ হারায়)। Chain: variance 0.14%, D21 6.6% — ২০-৫০ গুণ খারাপ। (sampling আগেই মৃত।) dNTC landmark অংশ = Nyström/ISDF (মৃত)।
File	experiments/probes/r11_particle_gate.py

D20 পুরোনো kappa3-এর aggregate rank-k CP, factor-গুলো B দিয়ে transport

মৃত

উৎস: Round 11: aggregated rank-k old kappa3 (T_old ~ sum sigma_a u_a x u_a x v_a, k ~ 230)

কী করতে হবে	সব পুরোনো source একসাথে একটা CP-তে; transport প্রতি factor-এ exact; D21 = (U o U) diag(sigma) V^T।
প্রমাণ / এখন পর্যন্ত	নতুন run লাগেনি, আগের মাপা প্রমাণ: (১) pooled old tensor-এর (a)|(bc) unfolding-এ 2% পেতে rank ~250 লাগে (32/128/256 -> 35/7.8/1.6%) — এটা CP rank-এর নিম্নসীমা, বাস্তবে CP আরও অনেক বেশি rank চায়; (২) chain-এ CP-rank capping 2%-এর জন্য ~8n column চেয়েছে; (৩) forum-এর rank-4608 CP channel 1.07e-7 (chain-এর ৫ গুণ খারাপ)। দাবি করা 'rank-230-এ 2%' আসলে D21 slice-এর matrix rank, tensor-এর CP rank না। প্রতি layer-এ ~3n নতুন rank-এর birth যোগ হয়, আর re-compression (factored CP-ALS) প্রতি sweep-এ ~2u খরচ।
File	docs notes F88/K3 pooled-core rows

D21 Young tier-এর mixed forward/reverse বা hierarchical contraction order

মৃত

উৎস: Sonnet 5 subagent (Round 10 A1, contraction-order search)

কী করতে হবে	Young tier-কে tensor network হিসেবে লিখে সব গুণের ক্রম খোঁজা (opt_einsum + হাতে বানানো mixed order)।
প্রমাণ / এখন পর্যন্ত	Ledger পুনরুৎপাদন: transport 54.5u (108 product), D21 hub 50.5u (100 product), মোট 105.0u। Hadamard আগে তৈরি করতে হয়, আর code আগেই 2টা right-factor contraction-এ fuse করা — এটাই floor। Transport chain-এর খরচ ক্রম-নিরপেক্ষ (সব n×n)। Reverse-style suffix precompute +75%, প্রতি age আলাদা +150%, batching FLOP-নিরপেক্ষ। সংশোধন: A = P·R_b, R_b একটা স্থির পূর্ণ n×n birth matrix (diagonal না) — A আর P একই left map-এ transport হয় (1e-14 পর্যন্ত মেলে); আগের 'P^-1 A 100-970% বদলায়' ছিল ill-conditioned inverse-এর ভুল (একটা Round 10 উত্তর এটা ধরেছে)। খরচে লাভ নেই: A entry-wise বানাতে n^3 লাগে। | বাইরের ৪টা Round 10/10b উত্তর একমত: 193 square product (39 P + 54 A + 100 D21) = 98.4u core, কোনো order কম না। Astra: float64 numerical packing — meter float64-কে ২ গুণ ধরে, লাভ শূন্য (float16 = float32 = 1.0, কোনো precision ছাড় নেই)। একটা উত্তর ভুল প্রম্পটের diag(a_b) ধরে 'A কখনো বানাতে হয় না' দাবি করেছে — প্রযোজ্য না। আরেকটা উত্তরের 49-55u দাবি অন্য এক validator ভুল হিসাব হিসেবে ধরেছে।
পরের ধাপ	Young tier সস্তা করতে representation বদলাতে হবে, ক্রম না।
File	experiments/probes/sonnet10_*.py; consultations/sonnet/ROUND10_sonnet_report.md

D22 κ4-এর সস্তা per-layer নিয়ম (Astra kernel সস্তা করা, scale-mixture, C⊗C), B2/WK12 অর্ধেক পরিবার, λ refit, B1 স্মৃতি carrier

মৃত

উৎস: Opus 5.5 subagent (Round 12 accuracy thread)

কী করতে হবে	Leaderboard-এর 15-25% accuracy ফাঁক কোথা থেকে, তার খোঁজ।
প্রমাণ / এখন পর্যন্ত	নতুন ReLU physics গভীরে সত্যিকারের κ4-এর মাত্র 1-4% (L8 থেকে; L2-তে 1.02 sanity)। সত্যিকারের κ4 linear-ভাবে বহন করলে level 83-90%, pattern corr 0.77-0.80 (chain 0.26-0.34)। Chain-এর κ4-এ (1,1,1,1) all-distinct অংশ গঠনগতভাবেই নেই। Scale-mixture/C⊗C corr ≤0.09। FB 2.0 +3.8%/+3.2%, λ 0.85 +1.8%/+1.0% (MLP#0/synth)। D21 oracle: শুধু feedback-এ ×0.9999 (cross-talk মৃত), সব জায়গায় ×0.758 (নিখুঁত κ3 slice = -24%)। B1: সেরা ~2-product carrier L15-এ D21-এর 27% মিস; ঘাটতি 40%, rank90 ~85, আগের ধাপের সাথে corr -0.0004। 'κ4→κ3 feed arm' chain-এ আগেই আছে।
পরের ধাপ	Q18
File	experiments/probes/opus12_*.py; consultations/fable/ROUND12_opus_report.md

Q18 κ4 স্মৃতির দিগন্ত: শেষ 1-4 ধাপের birth কতটা pattern ধরে?

মৃত

উৎস: Opus 5.5 subagent (Round 12)

কী করতে হবে	opus12_k4_carry.py বাড়িয়ে সত্যিকারের κ4 শুধু শেষ h ধাপ (h=1..4) linear-ভাবে বহন করা; pattern corr আর level মাপা।
প্রমাণ / এখন পর্যন্ত	κ4-এর গভীর pattern = বহন করা স্মৃতি (corr 0.77-0.80 বনাম chain 0.3); κ4 oracle -30%। | ফল (q18_k4_horizon.py, N=1e6, MLP#0): L−h-এ সব স্মৃতি মুছে Gaussian দিয়ে h ধাপ আসল network চালালে decisive neuron-এ κ4 level L12: h=1/2/3/4/6 → 2/6/12/18/35%, L16: 3/2/5/9/20%; teacher-এর সাথে pattern corr L12 0.23/0.40/0.53/0.67/0.78, L16 0.20/0.41/0.59/0.65/0.77; best-scale errG4 h=2: 0.90/0.99, h=6: 0.37/0.63 — chain 0.19/0.21। শেষ ২ ধাপের জন্ম κ4-এর মাত্র 2-6% বহন করে; ৬ ধাপেও 20-35%। κ4-এর স্মৃতি κ3-এর মতোই লম্বা: young κ4 carrier মৃত; κ4 lever-এর জন্য পুরো κ4 source chain লাগবে — খরচে বন্ধ।
খরচ	0u, ~30 মিনিট offline
পাস করার শর্ত	শেষ 2 ধাপ ঘাটতির ≥ অর্ধেক ধরলে young κ4 carrier বানানো (~4 product/layer ≈ 28u, +11%); ship শুধু দুই network-এ raw ≥12% হলে
File	experiments/probes/q18_k4_horizon.py

Q19 বন্ধ করা online mean correction (CORR_BETA) v40fb-এর trajectory-তে নতুন করে fit করা

উৎস: নিজের (504aldo findings log F47 পড়ে, 25 Sep)

মৃত

কী করতে হবে	v40fb-এ online mean correction আছে কিন্তু বন্ধ (NO_CORR=1): পুরোনো V16b-এর জন্য fit করা β নতুন base-এ ক্ষতি করে, 'refit না হওয়া পর্যন্ত বন্ধ' — refit কখনো হয়নি। F47 পদ্ধতি: teacher-forced trajectory-তে (আগের layer-এর সত্যিকারের mean বসিয়ে) 13টা per-neuron feature (mu, var, sigma, alpha, phi, Phi, pred, D3, |D21| row-sum, K4 ...) থেকে প্রতি layer-এর fresh error-এর ridge fit, তারপর loop-এর ভেতরে online প্রয়োগ। খরচ প্রায় শূন্য (13 dot/neuron/layer)।
প্রমাণ / এখন পর্যন্ত	F47: V16b base-এ 3.65e-8 -> 2.52e-8 = 1.45x (5 train / 3 test MLP, train~test, generalizes)। আমাদের পুরোনো 'learned OUTPUT correction dead' ছিল loop-এর বাইরের correction — এটা আলাদা। ঝুঁকি: v40fb-এর regen/vecww base ইতিমধ্যে এর একাংশ ধরে থাকতে পারে; লাভ অজানা। | ফল (25 Sep, MLP#0, experiments/variants/estimator_q19corr.py + experiments/chain/q19_run.py): correction বন্ধ রাখলে variant হুবহু shipped (2.2364e-8)। Teacher-forced run-এ প্রতি layer-এর fresh error-এর rms 1.5-6.7e-5; 13টা feature দিয়ে একই network-এ in-sample R^2 মাত্র L3 0.15, L8/12/15 0.02 — 13 parameter / 1024 neuron-এর সুযোগ-সীমার (~0.013) প্রায় সমান, অর্থাৎ কোনো signal নেই (F47-এ V16b base-এ R^2 ছিল 0.3-0.6)। v40fb-এর regen/vec+ww base আগেই অনুমানযোগ্য অংশ শুষে নিয়েছে। বাড়তি তথ্য: mean জোর করে সত্যি রাখলে final MSE 2.24e-8 -> 4.2e-9 — final error-এর ~80% হলো আগের layer-এর mean error জমে বয়ে আসা।
খরচ	~0u (13 dot/neuron/layer)
পাস করার শর্ত	held-out MLP-এ paired raw ≥3% কমলে Kaggle 100-MLP; fit শুধু local MLP-এ, leaderboard-এ না
File	experiments/variants/estimator_q19corr.py; experiments/chain/q19_run.py

D23 Layer অনুযায়ী rank/বয়সসীমা পুনর্বণ্টন (শেষের layer-এ বেশি খরচ) দিয়ে এক-এর-বদলে-এক নিয়ম ভাঙা

উৎস: নিজের (25 Sep)

মৃত

কী করতে হবে	নিখুঁত κ3 input (slice + d3) শুধু নির্দিষ্ট layer window-এ বসিয়ে দেখা লাভ কোথায় জমা।
প্রমাণ / এখন পর্যন্ত	Oracle (opus12_d21oracle.py + OPUS_OR_LMIN/LMAX, plain chain, MLP#0 / synthetic): সব layer 0.608 / 0.715; layer ≥8 0.637 / 0.754; ≥12 0.704 / 0.863; ≥14 0.848 / 0.903; ≤11 0.884 / 0.837 (প্রভাব গুণফলে যোগ হয়: 0.884×0.704≈0.62)। লাভ layer 8-16 জুড়ে ছড়ানো, শেষ ২-৩ layer-এ জমা না। আর আগের মাপ (notes K3ad/F-A5): পুরোনো source একদম না ছেঁটে (সব dense, exact) slice error 6.7%->6.6%, final MSE মাত্র -3.9% (+19% খরচ) — κ3 error compression থেকে আসে না, K3 formulation-এর জন্মে (all-distinct post-ReLU κ3) অন্তর্নিহিত। তাই rank/বয়সসীমা যেভাবেই ভাগ করা হোক, বড় লাভ সম্ভব না।
File	experiments/variants/opus12_d21oracle.py; results/summaries/teacher_eval_q20_late_k3oracle.json