Moonshot Blueprint: নতুন architecture বানাতে যা যা জানা দরকার

ARC White-Box Estimation Challenge 2026, Phase 2 · foyshal_sk · শেষ হালনাগাদ: ২৪ সেপ্টেম্বর ২০২৬, সন্ধ্যা (বাংলাদেশ সময়) · জমা দেওয়ার শেষ সময়: ১৮ অক্টোবর ভোর ৫:৫৯ (বাংলাদেশ সময়)।
এই দলিল মুনশটের "নকশার শর্ত": আমাদের সব পরীক্ষা থেকে যা নিশ্চিতভাবে জানা গেছে, কোন পথ বন্ধ, আর নতুন architecture-কে কোন কোন শর্ত পূরণ করতেই হবে। বিস্তারিত প্রমাণ আছে Complete Notes PDF-এর K3 অংশে (অংশের নম্বর বন্ধনীতে দেওয়া), আর ধারণাগুলোর তালিকা Experiment Queue PDF-এ।

১. লক্ষ্য আর দূরত্ব

Score = শেষ layer-এর MSE × max(0.1, FLOPs / 2^{41})। খরচ মাপার একক: 1u = 2^{31} FLOPs, তাই util 0.1 = ~102u।

স্থান (২৪ সেপ্টেম্বর)	দল	Adjusted	Raw MSE	Util	খরচ (u)
১	J2W	2.1e-9	1.64e-8	0.131	~134
২	suliman_tadros	2.2e-9	1.63e-8	0.138	~141
৩	marius_binner	2.3e-9	1.56e-8	0.147	~151
৪	a_s6	2.5e-9	2.00e-8	0.126	~129
৩৩	**আমরা (#332110)**	**5.1e-9**	**2.11e-8**	**0.244**	**~249**

Top-3-এ যেতে (adjusted ≈ 2.25e-9) কোন খরচে কত raw MSE লাগবে:

খরচ (u)	250 (এখন)	205	154	133	123	110	≤102 (floor)
দরকারি raw MSE	9.2e-9	1.12e-8	1.50e-8	1.73e-8	1.87e-8	2.10e-8	2.25e-8

মূল কথা: শুধু accuracy বাড়িয়ে top-3 সম্ভব না (raw 9e-9 লাগবে, কেউ এর কাছেও নেই)। কিন্তু **বর্তমান accuracy রেখেই খরচ ~110u-তে (এখনকার ৪৪%) নামাতে পারলে top-3, আর ≤102u-তে নামালে #1-এর সমান।** a_s6 দেখিয়েছে যে প্রায় আমাদের accuracy (2.0e-8) ~129u-তে সম্ভব। তাই মুনশটের সংজ্ঞা: **একই accuracy, খরচ ≤ ~115u**। খরচ যত কমবে, accuracy তত ছাড় পাবে (টেবিল দেখুন)।

২. আমরা কতদূর: সৎ মূল্যায়ন

ধাপ	অবস্থা
১. Error কোথা থেকে আসে (error map)	✅ সম্পূর্ণ। কোন channel কতটা error দেয় আর কেন, মাপা আছে (অংশ ৪)।
২. খরচ কোথায় যায় (cost ledger)	✅ সম্পূর্ণ। প্রতিটা matmul কোন line থেকে আসে, মাপা আছে (অংশ ৫)।
৩. কোন পথ বন্ধ	✅ অনেকটা। Linear compression-এর পুরো পরিবার গাণিতিকভাবে বন্ধ, সময়-অক্ষের কৌশলও বন্ধ (অংশ ৬-৭)।
৪. নতুন mechanism খুঁজে পাওয়া	⏳ **এখনও পাওয়া যায়নি।** Round 10 (young tier) আর Round 11 (কী represent করা হচ্ছে সেটা বদলানো) চলছে।
৫. এক layer-এর falsifier পাস	⬜ বাকি
৬. একটা MLP-এ prototype, score < chain × 0.8	⬜ বাকি
৭. Kaggle 100-MLP paired যাচাই → submit	⬜ বাকি

অর্থাৎ আমরা **ধাপ ৪-এ** আছি। খোঁজার জায়গা অনেক ছোট হয়ে গেছে, এখন বাকি সম্ভাবনা মাত্র কয়েকটা (অংশ ৮)। হাতে আছে ~২৩ দিন। একটা mechanism পাওয়া গেলে ধাপ ৫-৭-এর যন্ত্রপাতি (captures, teacher, paired harness, Kaggle runner) তৈরি আছে। তাই পরের ধাপগুলো দ্রুত হবে: falsifier কয়েক মিনিটে, prototype ১-২ দিনে, 100-MLP যাচাই ~৫ ঘণ্টায়।

৩. বর্তমান পদ্ধতি এক নজরে (যেটা ভাঙতে হবে)

V29/V31 factorised K3 chain (504aldo, MIT): প্রতি layer-এ mean, covariance C আর κ3-কে **source-এর যোগফল** হিসেবে বহন করে। প্রতিটা ReLU একটা নতুন source জন্ম দেয়। Source-এর legs P, $A = P \cdot a_b$ ($a_b = \mathrm{diag}(\Phi) C_{off}$)।

- Young tier (বয়স ≤ ৪) dense legs রাখে। পুরোনো source-গুলো shared basis-এ থাকে (rank 384 / 224)। κ4 memoryless (λ law)।
- Mean আর covariance বের হয় bivariate Wick/Edgeworth closure দিয়ে।

৪. Error map: accuracy কোথায় হারায় (K3ab–K3ad)

- **C1.** দুটো closure-ই সঠিক। সত্যিকারের input দিলে mean closure-এর error 9e-11। তাই সব error আসে closure-এর **input** থেকে।
- **C2.** Channel oracle (প্রতি layer-এ সত্যিকারের মান বসালে final MSE কত কমে): **variance −47%**, **κ4 diagonal −30%** (শুধু mean closure দিয়ে কাজ করে), **κ3 diagonal −14%**, **তিনটা একসাথে −94%**।
- **C3.** Error-এর উৎস প্রতি layer-এ নতুন করে জন্মানো κ3-এর **all-distinct** অংশ, মানে post-ReLU $\kappa3(h_i,h_j,h_k)$।
  - এই অংশ নিজের তুলনায় ৯–১৬% ভুল, আর D21 slice-এর error-এর ৯১–৯৬% এখান থেকেই আসে।
  - Slice error depth-এর সাথে ৪% থেকে ৭% পর্যন্ত বাড়ে, আর এটা এলোমেলো: slope 1.00, R^2 0.996।
  - এর সাথে κ4-এর multi-index input-এর ভুলও আছে।
- **C4.** ভুল জমে দুই পথে: mean দিয়ে (প্রতি layer-এ gain 0.65–0.96) আর covariance দিয়ে। Variance-এর ভুল আসলে off-diagonal post-ReLU covariance-এর ভুল, প্রতি entry-তে নতুন ~4.2e-5।

৫. Cost ledger: খরচ কোথায় যায় (K3ah)

অংশ	খরচ (u)	মন্তব্য
Young source transport	~54	বয়স ১–৪, dense n×n legs
Young source D21 contraction	~50	(X∘P)Yᵀ ধরনের product
Join (source-কে shared basis-এ ঢোকানো)	~41–46	range finder / eigen
Old tier (shared basis)	~41	rank 384 / 224
Thin feedback legs	~15	
Strassen additions	~12	
Covariance + closure	~8	সস্তা!
মোট	**~249**	৮৮% matmul

C5. এক-এর-বদলে-এক নিয়ম: chain-এর ভেতরের যেকোনো knob (age gate, rank, pass, screening, join rebuild, exact old tier, R_FB) ~১% খরচ কমালে ~১% accuracy হারায়, আর উল্টোটাও সত্য। উদাহরণ:

- exact old tier: MSE −৩.৯%, খরচ +১৯%
- R_FB 128: MSE −৩.১%, খরচ +৪৩%
- join transport: খরচ −৬.৬%, MSE +১–৬%

তাই chain নিজের সেরা বিন্দুতেই বসে আছে। **খরচ অর্ধেক করা এই পরিবারের ভেতরে সম্ভব না।**

C6. লক্ষ্য করুন: covariance আর closure মাত্র ~৮u। সব খরচ κ3 বহন করায়। একটা Gaussian (শুধু κ2) chain খুব সস্তা, কিন্তু তার error ~১০ গুণ বেশি (no old tier: ×৩৫)।

৬. κ3 স্মৃতির গঠন (K3aj, আজকের পরীক্ষা)

পরীক্ষা	ফল	অর্থ
Horizon oracle: শুধু বয়স ≤ h-এর source রাখা	L15: h2 84%, h4 65%, h6 46%, h8 31%, h10 **16%** error	স্মৃতি **দীর্ঘ**: ১০ layer পুরোনো source-ও দরকার
Age-Gram (বয়সগুলোর পারস্পরিক মিল)	গড় cosine 0.29–0.39; প্রথম mode মোটের ~৮৮%; r=6 mode রাখলেও 8.5% error	সুসংগত (coherent), কিন্তু বয়সের অক্ষে low-rank না
Shift-stable carrier (L14→L15)	eps 2.9%, rho 0.944; carrier + birth দিয়ে মোট D21 13.9%	পাস না। তাছাড়া সমান ওজনের carrier, মানে মোট κ3 নিজেই, **হুবহু** transport হয়
Source-free dressed tree (DHMP)	পরের D21-এ 36–40% error (শর্ত 2.5%); tree আর সত্যিকারের all-distinct অংশের corr 0.43–0.54	All-distinct অংশের প্রায় অর্ধেক **স্মৃতি**, pair state থেকে আবার বানানো যায় না

C7. সময়ের সমস্যা নেই। মোট κ3 একটা linear map দিয়ে হুবহু এক object হিসেবে এগোয়। **সমস্যা পুরোপুরি spatial**: একটা ঘন n^3 tensor-কে সস্তায় ধরা।

C8. গাণিতিক দেয়াল (Sol): মোট κ3-এর এমন কোনো linear রূপ হয় না যা ছোট এবং সব dense M-এর transport-এ বন্ধ। Sym^3 হলো GL(n)-এর irreducible representation, তাই এমন রূপে ≥ $C(n+2,3) \approx 1.8\times10^8$ সংখ্যা লাগে। Tucker, TT, CP, vector-metric, age mode আর shared basis সবই এই দেয়ালে ঠেকে।

- আমাদের সংশোধন: M স্থির আর জানা। তাই আসল সীমা হলো ভবিষ্যৎ readout যতটুকু দেখে, প্রতি বাকি layer-এ ≤ n^2। Mid depth-এ এটা chain-এর ~$3kn^2$-এর কাছাকাছি।

- Lazy cubic circuit-এ (শুধু birth matrix + M রেখে reverse-mode) খরচ ≈ ২৪৫u, chain-এর সমান। দুটো একই tensor network-এর দুই contraction order।

উপসংহার: tensor-টা কীভাবে factorise করা হয় সেটা বদলে লাভ নেই। বদলাতে হবে কী represent করা হচ্ছে।

৭. পুরোনো source কীভাবে শেষ mean-কে প্রভাবিত করে (K3m)

- **C9.** পুরোনো source-এর slice-এর প্রভাবের **~৮৬%** যায় পরের ১–২ layer-এর **mean shift** দিয়ে (variance → E[relu])। এই পথ কাছের layer-এ সীমিত আর full-rank। শুধু ~১৪% যায় low-rank final-variance পথে। তাই adjoint দিয়ে "শুধু দরকারি দিক" রাখা মৃত।
- **C10.** শেষের দিকের layer-এ পুরোনো D21 (n^3) বা পুরোনো d3 (diagonal, n^2), যেকোনোটা বাদ দিলে error budget ছাড়িয়ে যায়। Output-এর দিকে diagonal-এর গুরুত্ব বাড়ে।
- **C11.** Khatri–Rao দেয়াল: factored legs-এর Hadamard product-এর rank r(r+1)/2, যা r ≥ ৪৫ হলেই n। বাস্তবে spectrum সমতল আর noise-এর মতো, তাই sketch করতে d ≈ 10^8 লাগবে।

৮. বাকি পথগুলো (অগ্রাধিকার অনুযায়ী)

#	পথ	কেন সম্ভব	Falsifier / শর্ত	অবস্থা
M1	**Channel-direct**: κ3 tensor না রেখে পরের mean-এর দরকারি channel (variance, d3, κ4 diag, যে covariance এগুলোকে খাওয়ায়) সরাসরি হিসাব	C8 বলে tensor বহন করলে খরচ কমবে না। Final score নির্ভর করে শুধু কয়েকটা per-neuron channel-এর উপর (C2)।	≤125u; teacher data-তে এক layer-এ channel error ≤ chain-এর error	Round 11 prompt পাঠানো হচ্ছে
M2	**Young tier অর্ধেক খরচে** (~104u → ≤55u)	বীজগণিতে কিছু বাকি থাকতে পারে: A = P·a_b, পরপর source-এর shared propagator, age-1/2 closed form	D21 relative error ≤ 2% রেখে ≤55u	Round 10 prompt পাঠানো হচ্ছে; আমার নিজের দেখা বীজগণিতে এখনও কিছু পাইনি
M3	**Nonlinear, trajectory-specific statistic** (নির্দিষ্ট MLP-এর জন্য, linear representation না)	C8-এর দেয়াল শুধু linear আর সব-M-এর জন্য বন্ধ state-এ প্রযোজ্য	নির্দিষ্ট প্রস্তাব আসলে ঠিক হবে	খোলা
M4	Accuracy দিক: fresh all-distinct κ3 আর κ4 pattern ঠিক করা	Oracle: κ4 −30%, variance −47%	খরচ না বাড়িয়ে MSE −১০%+ (তবে C5 মনে রাখতে হবে)	আংশিক (FB_SCALE 1.25 পাঠানো হয়েছে)
M5	ছোট লাভ: join aug64 (Q16), FB × beta grid	teacher-এ score −০.৫%	100-MLP paired < 1 − 2 SE	Kaggle-এ চলছে

৯. যেকোনো নতুন প্রস্তাবের জন্য চেকলিস্ট

1. এটা কি C8-এর দেয়ালে পড়ে, মানে একই κ3 tensor-এর অন্য factorisation? পড়লে বাদ।
2. পুরোনো source-এর তথ্য (C9: ১০+ layer পুরোনো, মোটের ~৮৮% coherent) কোথায় যায়? এটা বাদ দিলে ৩৬–৪০% error (DHMP)।
3. খরচ n^3 product-এ গুনে দেখা: ≤ ~১১৫u? (1 dense 1024^2 product ≈ 0.5u Strassen L5-এ; ~২৩০টা product = ১১৫u)
4. সংরক্ষিত data-তে এক layer-এর falsifier আছে কি? (teacher: layer 3/7/11/14/15/16-এর pre/post mean, C, Y21, κ4 diag; captures: L7/11/14/15-এর প্রতিটা source)

5. Grader-এর শর্ত: ৮ GB RAM, float32, residual time < 0.4 s, শুধু flopscope + whestbench + stdlib, কোনো print নয়।

১০. যে পথগুলো মৃত (আবার চেষ্টা করা যাবে না)

পরিবার	যা মাপা হয়েছে
Tucker / TT / CP / ISDF / vector-metric compression	2% পেতে rank ≈ 250–300 লাগে, মানে প্রতি layer-এ 500u+ (C8 এর কারণ ব্যাখ্যা করে)
Short horizon (FHQR), age pooling, age mode	h=10-এও 16%; r=6-এও 8.5%
Shift-stable carrier	2.9%, আর মোট κ3 তো আগে থেকেই হুবহু বহন হয়
Source-free tree (DHMP)	36–40%
Sampling / control variate	10^4 sample-এর খরচ 156u, তাতে variance 1.4% ভুল (লাগবে 0.1%); CV-এর জন্য corr ≥ 0.997 দরকার
Adjoint দিয়ে low-rank পথ	প্রভাবের মাত্র ১৪% low-rank
Learned per-neuron correction, copula, 13-feature regression, star source, V39 depth multiplier, pairwise κ4 transport	100 MLP-এ বা teacher-এ কোনো লাভ নেই
Join rebuild, age gate, rank, pass, screening	এক-এর-বদলে-এক নিয়ম (C5)

১১. সময়সূচি (বাংলাদেশ সময়)

তারিখ	লক্ষ্য
২৪–২৮ সেপ্টেম্বর	Round 10/11-এর উত্তর triage; প্রতিটা প্রস্তাবের falsifier সংরক্ষিত data-তে চালানো
~২ অক্টোবর	একটা mechanism এক layer-এর falsifier পাস করবে (না হলে M4/M5-এ সময় দেওয়া)
~৮ অক্টোবর	একটা MLP-এ prototype, score < chain × 0.8
~১২ অক্টোবর	Kaggle 100-MLP paired যাচাই
১৫–১৭ অক্টোবর	Submit, আর final দুটো submission বেছে নেওয়া